

# 1. Marco teórico

## 1.1. Correlación lineal

Cuando se tiene una variable controlada  $x$  y una dependiente  $y$  tenemos el modelo lineal

$$Y = \beta_0 + \beta_1 x + \epsilon \quad (1)$$

que implica entonces el modelo para análisis de rendimiento promedio:

$$E(Y) = \beta_0 + \beta_1 x. \quad (2)$$

Si la variable  $x$  es un valor observado de una variable  $X$ , al establecerse una relación funcional y al basarse en (2) se implica el modelo

$$E(Y|X = x) = \beta_0 + \beta_1 x \quad (3)$$

que supone la esperanza condicional de  $Y$  para un valor fijo de  $X$  en una función lineal del valor  $x$ . Al suponer que la variable aleatoria vectorial  $(X, Y)$  tiene una distribución normal bivariable con  $E(X) = \mu_X$ ,  $E(Y) = \mu_Y$ ,  $V(X) = \sigma_X^2$ ,  $V(Y) = \sigma_Y^2$ , el coeficiente de correlación  $\rho$  puede demostrar que

$$E(Y|X = x) = \beta_0 + \beta_1 x, \quad \text{donde } \beta_1 = \frac{\sigma_Y}{\sigma_X} \rho. \quad (4)$$

Si  $(X, Y)$  tiene una distribución normal bivariable, entonces la prueba de independencia es equivalente a probar si el coeficiente de correlación  $\rho$  es igual a cero. Denotando con  $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$  una muestra de aleatoria de distribución normal bivariable. El estimador de máxima probabilidad de  $\rho$  está dado por el coeficiente de correlación muestral:

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}}. \quad (5)$$

Puede expresarse  $r$  en términos de cantidades conocidas:

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} = \hat{\beta} \sqrt{\frac{S_{xx}}{S_{yy}}}. \quad (6)$$

Cuando  $(X, Y)$  tenga una distribución normal bivariable, se sabe que

$$E(Y|X = x) = \beta_0 + \beta_1 x, \quad \text{donde } \beta_1 = \frac{\sigma_Y}{\sigma_X} \rho. \quad (7)$$

Pruebas en las que los conjuntos de hipótesis que contienen  $\beta_1$ , por ejemplo,  $H_a: \beta_1 = 0$  contra  $H_a: \beta_1 > 0$   $H_a: \beta_1 < 0$ , así como  $H_a: \beta_1 > 0$  contra  $H_a: \beta_1 \neq 0$  pueden estar basadas en el estadístico

$$t = \frac{\hat{\beta}_1 - 0}{S/\sqrt{Sxx}}, \quad (8)$$

Wackerly, Mendenhall III y Scheaffer consideran que “parecería lógico usar  $r$  como estadístico de prueba para probar hipótesis más generales acerca de  $\rho$ , pero la distribución de probabilidad para  $r$  es difícil de obtener.” Dennis D Wackerly, William Mendenhall III y Richard L Scheaffer. *Estadística matemática con aplicaciones*. Trad. por Jorge Humberto Romo Mufioz. 7.<sup>a</sup> ed. Ciudad de México: Cenage Learning, 2009. ISBN: 9780495110811 Sin embargo, en muestras moderadamente grandes podemos probar la hipótesis  $H_0: \rho_1 = \rho_0$  con una prueba  $Z$  en la que

$$Z = \frac{(\frac{1}{2}) \ln(\frac{1+r}{1-r}) - (\frac{1}{2}) \ln(\frac{1+\rho}{1-\rho})}{\frac{1}{\sqrt{n-3}}}. \quad (9)$$

Si  $\alpha$  es la probabilidad deseada de cometer un error tipo I, la forma de la región de rechazo depende de la hipótesis alternativa. Las diversas alternativas de interés más frecuente y correspondientes regiones de rechazo son las siguientes:

$$H_a: \rho > \rho_0, \quad RR: z > z_\alpha \quad (10)$$

$$H_a: \rho < \rho_0, \quad RR: z < -z_\alpha \quad (11)$$

$$H_a: \rho \neq \rho_0, \quad RR: |z| > z_\alpha/2 \quad (12)$$

La suma de los cuadrados del error  $SSE$ , es una alternativa para medir la variación en valores que permanecen sin explicación después de usar las  $x$  para ajustar el modelo de regresión lineal simple, la razón  $SSE/S_{yy}$  la proporción de la variación total en las  $y_i$  que este modelo no explica. El coeficiente de determinación se puede escribir como

$$r^2 = \left(\frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}\right)^2 = \left(\frac{S_{xy}}{S_{xx}}\right)\left(\frac{S_{xy}}{S_{yy}}\right) = \left(\frac{\hat{\beta}_1 S_{xy}}{S_{yy}}\right) = \frac{S_{yy} - SEE}{S_{yy}} = 1 - \frac{SSE}{S_{yy}}. \quad (13)$$

Podemos interpretar a  $r^2$  como la proporción de la variación total en las  $y_i$  que es explicada por una variable  $x$  en un modelo de regresión lineal simple.

## 1.2. Modelo de base de datos relacional

código	CHAR	fecha	DATE	estado	INTEGER
MX01		2020-01-01		1	
MX02		2020-01-02		1	
MX03		2020-01-03		0	

[Dat12]

### 1.3. Probabilidad condicional

La probabilidad condicional tiene las mismas características que la probabilidad, pero  $P(\cdot|B)$  actualiza nuestra incertidumbre acerca de los eventos para reflejar la evidencia observada en  $B$ .

Si  $A$  y  $B$  son eventos con  $P(B) > 0$  entonces la *probabilidad condicional* de  $A$  dado  $B$  denotado por  $P(A|B)$ , se define como

$$P(A|B) = \frac{P(A \cap B)}{P(B)}. \quad (14)$$

Se denomina probabilidad a priori de  $A$  a  $P(A)$  y probabilidad a posteriori de  $A$  a  $P(A|B)$  y es importante mencionar que  $P(A|B) \neq P(B|A)$ .

La probabilidad condicional es la razón de dos probabilidades y sus consecuencias, la primera de ellas se obtiene moviendo el denominador en la definición al otro lado de la ecuación, para cada evento  $A$  y  $B$  con posibilidades positivas,

$$P(A \cap B) = P(B)P(A|B) = P(A)P(B|A). \quad (15)$$

se le conoce como teorema de la *probabilidad de la intersección de dos eventos*. Aplicando repetidamente el teorema (15) aplicado a la intersección de  $n$  eventos obtenemos el teorema de *probabilidad de la intersección de  $n$  eventos*. Para cualquier evento  $A_1, \dots, A_n$  con probabilidad  $P(A_1, A_2, \dots, A_{n-1}) > 0$ ,

$$P(A_1, A_2, \dots, A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1, A_2) \dots P(A_n|A_1, \dots, A_{n-1}). \quad (16)$$

Otro teorema que relaciona a  $P(A|B)$  con  $P(B|A)$  es la regla *regla de Bayes*:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (17)$$

que se origina directamente del teorema (15) y a su vez se origina directamente de la definición de probabilidad condicional, sin embargo, la regla de Bayes tiene importantes aplicaciones e implicaciones en probabilidad y estadística, ya que en ocasiones es más fácil encontrar  $P(B|A)$  que  $P(A|B)$  o viceversa. Otra forma de escribir la regla, es en términos de sus **odds COMO SE DICE EN ESPAÑOL, ¿cuota?**, las **odds** de un evento  $A$  son

$$odds(A) = P(A) \frac{P(A)}{P(A^c)}. \quad (18)$$

Al tomar la expresión  $P(A|B)$  y la dividimos entre la  $P(A^c|B)$ , ambas de la regla de Bayes llegamos a la *forma de odds de la regla de Bayes* que para cualquier eventos  $A$  y  $B$  con posibilidades positivas, las *odds de  $A$  after conditioning on  $B$*  son

$$\frac{P(A|B)}{P(A^c|B)} = \frac{P(B|A)}{P(B|A^c)} \frac{P(A)}{P(A^c)}. \quad (19)$$

En este caso las *odds a posteriori*  $P(A|B)/P(A^c|B)$  son iguales a las *odds a priori*  $P(A)/P(A^c)$  por el factor  $P(B|A)/P(B|A^c)$  lo que se le conoce en estadística como *función de verosimilitud*.

La ley de Bayes es usada en ocasiones en conjunto con la *ley de probabilidad total*, que es esencial para descomponer problemas complicados de probabilidad en problemas partes: Si  $A_1, \dots, A_n$  es una partición de una muestra del espacio  $S$ , con  $P(A_i) > 0$  para todo  $i$ , entonces

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i). \quad (20)$$

Prueba: como los  $A_i$  forman una partición de  $S$ , podemos descomponer  $B$  como

$$B = (B \cap A_1) \cup (B \cap A_2) \cup \dots \cup (B \cap A_n). \quad (21)$$

como las partes están disjuntas, podemos agregar sus posibilidades para obtener  $P(B)$ :

$$P(B) = P(B \cap A_1) + P(B \cap A_2) + \dots + P(B \cap A_n). \quad (22)$$

Aplicando el teorema (15) a cada  $P(B \cap A_i)$  obtenemos

$$P(B) = P(B|A_1)P(A_1) + \dots + P(B|A_n)P(A_n). \quad (23)$$

La *ley de probabilidad total* dice que para obtener la probabilidad incondicional de  $B$ , tenemos que dividir el espacio muestra en cortes disjuntos  $A_i$ , encontrar la probabilidad condicional de  $B$  en cada corte, después tomar la suma pesada de las probabilidades condicionales, donde los pesos son las probabilidades  $P(A_i)$ .

## 1.4. Variables aleatorias y sus distribuciones

Dado un experimento con una muestra en espacio  $S$ , una *variable aleatoria* es una función del mismo espacio  $S$  para los números reales  $\mathbb{R}$ . Una variable aleatoria  $X$  asigna el valor numérico  $X(s)$  a cada resultado posible  $s$  del experimento. La aleatoriedad viene del hecho que tenemos un experimento aleatorio (con probabilidades descritas por la función de probabilidad  $P$ ). Las variables aleatorias simplifican la notación y expanden la habilidad de cuantificar y resumir resultados de experimentos.

Se dice que una variable  $X$  es discreta cuando si hay una lista finita de valores  $a_1, a_2, \dots, a_n$  o una lista infinita de valores  $a_1, a_2, \dots$  de tal forma que  $P(X = a_j \text{ para algún } j) = 1$ . Si  $X$  es una variable aleatoria discreta, entonces el grupo infinito o contable de valores  $x$  tal que  $P(X = x) > 0$  se llama *soporte* de  $X$ . En contraste una variable aleatoria continua puede tomar cualquier valor real en un intervalo.

La forma más natural de expresar la distribución de variables aleatorias discretas es la *función de probabilidad* [BH19] (PMF, por sus siglas en inglés) que, para una  $X$  discreta, es la función  $p_X$  dada por  $p_X(x) = P(X = x)$

Maybe[BH19]

## Fuentes

- [BH19] Joseph K. Blitzstein y Jessica Hwang. *Introduction to Probability [Introducción a la probabilidad]*. 2.<sup>a</sup> ed. Texts in Statistical Science [Textos en ciencia estadística]. Florida: Chapman y Hall/cRC, 2019. ISBN: 9781138369917.
- [Dat12] C. J. Date. *SQL and Relational Theory: How to Write Accurate SQL Code [SQL y teoría relacional: Cómo escribir código SQL correcto]*. 2.<sup>a</sup> ed. California: O'Reilly Media, 2012. ISBN: 9781449316402.
- [WMIS09] Dennis D Wackerly, William Mendenhall III y Richard L Scheaffer. *Estadística matemática con aplicaciones*. Trad. por Jorge Humberto Romo Muñoz. 7.<sup>a</sup> ed. Ciudad de México: Cengage Learning, 2009. ISBN: 9780495110811.